

리뷰핏 ReviewFit

화장품 리뷰 40만 건 · 머신러닝 + 딥러닝 감성 분석 서비스



상품 추천

감성 점수 기반
상품 랭킹



상품 비교

감성 분포
브랜드 비교



모델 리포트

6개 모델
성능 비교



직접 분석

리뷰 텍스트
실시간 판정

데이터 수집



올리브영

834개 상품 · 4카테고리

172K건



쿠팡

화장품 카테고리

36K건




무신사

뷰티 카테고리

194K건

총 402,438건

클래스 분포 (Class Imbalance)



■ 긍정 86.8% ■ 부정 9.5% ■ 중립 3.7%

크롤링 방법

1

카테고리
랭킹 페이지

판매 상위 100개
상품 URL 수집

2

리뷰 수
사전 확인

API stats 호출
최소 리뷰 수 게이트

3

리뷰 API
커서 반복

POST 커서 방식
비로그인 전체 수집

4

JSONL 저장
이어받기

완료 상품 스킵
중단 후 재개 가능

Rate Limit (429)

약 70개 상품(2.5h) 후 발동
→ 수 시간 대기 후 재개

API 역분석

Selenium 없이 모바일 API
커서 방식으로 직접 호출

부정 리뷰 보충

별점 낮은 순(RATING_ASC)
추가 크롤링 스크립트 별도 구현

라벨링 설계

라벨링이 왜 어려웠나

① "없어서 좋다"를 부정으로 읽었다

"자극이 없어서 좋아요" ★5 → 부정 판정

"트러블없이 잘 써요" ★5 → 부정 판정

단어만 보고 맥락을 몰랐다

→ 부재 표현(없어서 / 없이)을
먼저 마스킹하는 로직 추가

② 조사 하나 차이로 865건 누락

"효과없어요" → 포착 ✓

"효과가 없어요" → 미포착 ✕

"효과도 없어요" → 미포착 ✕

"효과는 그닥이에요" → 미포착 ✕

→ 한국어 조사(가/도/는/를) 변형을
전부 쌍으로 등록해야 했다

③ 맥락 오독(같은 단어, 다른 의미)

"건조한 날씨에 꼭 필요한 제품" ★5 →
부정 판정 ('건조' 단어 때문에)

"건성 피부인데 너무 잘 맞아요" ★5 →
부정 판정

제품이 건조한 게 아니라 피부/날씨
설명인데 단어만 보고 잘못 판단

→ 문맥 예외 리스트 별도 관리

라벨 오류 발견과 수정

학습이 끝나고 나서야 알게 된 것들

Transformer v1 학습 완료 후 테스트: "그냥 평범해요" → 긍정 100% 출력

원인

"괜찮", "무난" → POSITIVE_KEYWORDS 에 등록돼 있었음

- 3점 리뷰가 neutral 이 아닌 positive 로 분류
- neutral 학습 데이터가 전체의 1.2% 밖에 안 됨
- 모델이 중립 리뷰를 긍정으로 오예측

"그냥 평범해요", "무난하게 쓸만해요" 같은
중립 표현을 전부 긍정으로 학습한 상태

수정 (v3)

"괜찮", "무난" → POSITIVE_KEYWORDS 에서 제거

- 3점 리뷰 + 긍부정 혼재 리뷰 → neutral 유지
- preprocessed_v3/ 별도 생성 후 전체 재학습

neutral 데이터
4,471건 → 5,657건 (+27%)

모델 선택 이유와 구조

머신러닝

TF-IDF + Logistic Regression

선택 이유

단어 빈도만 보는 통계 기반 모델. 문맥 없이 얼마나 되는지 비교 기준으로 선택

주요 설정

```
MAX_FEATURES = 100_000
NGRAM_RANGE = (1, 2) # unigram + bigram
MIN_DF = 2
MAX_DF = 0.95
MAX_ITER = 1_000
class_weight = "balanced"
solver = "lbfgs"
```

딥러닝 ①

BiLSTM (양방향 LSTM)

선택 이유

"자극이 없어서 좋아요" 처럼
앞뒤 문맥이 함께 의미를
만들어 양방향 선택

주요 설정

```
MAX_TOKENS = 80_000
SEQUENCE_LENGTH = 120
EMBEDDING_DIM = 128
LSTM_UNITS = 64 # Bidirectional → 실질 128
DROPOUT_RATE = 0.4
optimizer = "adam"
loss = "sparse_categorical_crossentropy"
EarlyStopping(patience=2, monitor="val_loss",
               restore_best_weights=True)
>> --class-weight balanced `
>> --batch-size 256 `
>> --epochs 10 `
>> --patience 2`
```

딥러닝 ②

KLUE-BERT (Transformer)

선택 이유

한국어 대규모 텍스트로 이미 학습된
모델. 어미/형태소 이해 상태에서
감성만 추가 학습해 보기 위해

주요 설정

```
model_name = "klue/bert-base"
max_length = 160
weight_decay = 0.01
warmup_ratio = 0.1
EarlyStopping(patience=2, metric="eval_loss")
load_best_model_at_end = True
```

```
>> --class-weight balanced `
>> --epochs 5 `
>> --batch-size 16 `
>> --learning-rate 2e-5 `
>> --fp16
```

학습 결과

모델	Accuracy	Macro F1	Weighted F1	Neg P	Neg R	Neg F1	Neu P	Neu R	Neu F1	Pos P	Pos R	Pos F1
Baseline	0.907	0.669	0.920	0.726	0.810	0.766	0.208	0.441	0.283	0.986	0.934	0.959
LSTM v1	0.880	0.661	0.913	0.857	0.742	0.795	0.143	0.782	0.242	0.994	0.900	0.944
LSTM v2	0.906	0.628	0.934	0.737	0.819	0.776	0.089	0.589	0.155	0.995	0.916	0.954
LSTM v3	0.893	0.666	0.913	0.771	0.731	0.751	0.196	0.586	0.294	0.987	0.921	0.953
Transformer v1	0.979	0.728	0.978	0.906	0.895	0.900	0.346	0.252	0.291	0.989	0.994	0.991
Transformer v2	0.964	0.788	0.963	0.870	0.871	0.871	0.536	0.475	0.503	0.987	0.991	0.989

LSTM은 왜 3번 학습했나?

모델 구조는 동일하고, 학습 데이터를 단계적으로 개선하며 재학습

v1 : 올리브영 데이터만 (~75K), 단순 별점 기반 라벨링

v2 : 외부 데이터 추가 (~402K), ★3 혼재 리뷰 중립 처리

v3 : 라벨링 규칙 전면 개선 (키워드 17개 → 55개, ★1~2 부정 복구)
같은 모델로 데이터 품질 개선 효과를 단계별로 검증

Transformer는 왜 2번 학습했나?

v1에서 중립 클래스 성능이 심각하게 낮아 재학습 필요

v1 : Neu Recall 0.252 – 중립 리뷰 4개 중 1개만 감지

v2 : LSTM과 동일한 v3 데이터로 재학습 → Neu F1 0.503 (2배 개선)

데이터 품질이 모델 성능을 결정한다는 것을 가장 직접적으로 보여준 결과

배포 및 서비스 시연

사전 계산 전략

40만 건 매 요청마다 예측 → 너무 느림 | `precompute_preds.py` 로 전체 예측을 파일로 사전 계산
첫 로딩 5~10초 후 탭 전환·필터링 즉시 응답 | `@cache_resource(모델)` · `@cache_data(DataFrame)`

탭 1

상품 추천

```
score = positive×0.6  
+ avg_rating/5×0.3  
+ log(리뷰수)×0.1
```

탭 2

상품 비교

브랜드·카테고리별
감성 분포 비교
(`skin_type`: 보조 정보만)

탭 3

모델 리포트

6개 모델
성능 비교표
(실제 학습 결과)

탭 4

직접 분석

리뷰 입력 →
`pos`≥0.6: 긍정
`neg`≥0.4: 부정
그 외: 판정 불확실

한계 & 아쉬운 점

가장 어려웠던 것: 중립(Neutral) 클래스

01

데이터 수집이 어렵다

화장품 리뷰는 구매자 특성상 긍정 편향 (positive 86.8%)
"그냥 보통이에요" 같은 중립 리뷰 자체가 플랫폼에 드물다

→ 3점 리뷰 직접 선별 추가 수집

02

학습이 어렵다

데이터가 적어 precision 낮음 (Transformer v3 기준 0.536)
모델이 중립을 긍정으로 오분류하는 경향 지속

→ 사람이 라벨링한 데이터 혼합

03

라벨링의 근본적 한계

현재 방식은 규칙 기반 자동 라벨링
아무리 정교해도 사람의 판단을 완전히 대체할 수 없다

→ Human annotation 이 궁극적 해결책

서비스에서는 $pos \geq 0.6 \cdot neg \geq 0.4$ 임계값 + "판정 불확실" 표시로 한계를 명시했습니다